

NAIST-IS-MT1551003

修士論文

逐次ベイズ推定による車線変更時刻の推定

浅山 和宣

2017 年 2 月 1 日

奈良先端科学技術大学院大学
情報科学研究科 情報科学専攻

本論文は奈良先端科学技術大学院大学情報科学研究科に
修士（工学）授与の要件として提出した修士論文である。

浅山 和宣

審査委員：

池田 和司 教授 （主指導教員）

久保 孝富 特任准教授 （副指導教官）

逐次ベイズ推定による車線変更時刻の推定*

浅山 和宣

内容梗概

自動車は世界各国の人々にとって、生活に欠かせない道具となりつつあるが、交通事故で命を落とす人は年間 120 万人に上る。事故を抑制する手段の一つとして、Advanced Driver Assistance System(ADAS) のような、運転を支援するデバイスの研究が近年進められてきてきた。このようなシステムにおいては、運転行動のモデリングによって、より進んだ機能が実現できると考えられる。運転行動のモデリングについての研究は数多くなされているが、周辺車両と運転行動の関連性についての研究は未だ少ない。そして、車線変更は周辺車両に大きく影響すると考えられる。そのため、本研究ではモデルの対象を車線変更に絞った。車線変更を予測し高い成果を上げた研究はいくつか存在するものの、何れも、周辺車両との関わりを明らかにしていないこと、ハンドル操作を始めてから推定を行うこと、推定時刻を得られないこと等の課題が残っている。そこで、本研究では、周辺車両との関わりから、車線変更開始までの時刻に分布をおき、逐次ベイズ推定により分布を更新することで車線変更推定を行った。この結果、分布を更新していくことでより誤差の少ない推定結果を得ることができ、周辺車両との関連性を用いて逐次的なアプローチを用いることが車線変更開始の推定に有用であることがわかった。

キーワード

運転行動, モデリング, 車線変更, 逐次ベイズ推定, 時系列予測

*奈良先端科学技術大学院大学 情報科学研究科 情報科学専攻 修士論文, NAIST-IS-MT1551003, 2017 年 2 月 1 日.

Estimation of Timing of Lane Changing by Sequential Bayes Inference*

Kazuki Asayama

Abstract

Moter vehicles are indispensable for world people to support them lives. On the other hand, there is the fact that 1.2 million people are killed by road accidents. Therefore the studies are has been conducted on driving support devices like Advanced Driver Assistance System(ADAS) which prevent traffic accidents. Driving model can make such system more intelligent. The driving model are well studied, however there are few interaction to surrounding vehicle in driving model. Moreover, a lane changing is strongly influenced by surrounding vehicle. Hence we studied about the lane changing model. There are several successful studies on lane changing prediction, however all have following tasks: not reveal relations about surronding vehicles, start prediction after turning the steering, not predict concrete estimation time. In this study, we estimated lane changing using surronging vehicles by assuming a distribution about starting time from lane changing, then update the distribution by sequential bayes inference. As a result, updating distribution can acquire result with less estimation error, therefore, this approach is useful to estimate time of lane changing.

Keywords:

Driving behavior, Modeling, lane changing, Sequential Bayes Inference, Time series prediction

*Master's Thesis, Department of Information Science, Graduate School of Information Science, Nara Institute of Science and Technology, NAIST-IS-MT1551003, February 1, 2017.

目次

図目次	iv
第 1 章 はじめに	1
1.1 背景	1
1.2 研究目的	2
1.3 本論文の構成	3
第 2 章 運転行動データと可視化	4
2.1 運転行動データ	4
2.2 特徴抽出	5
2.2.1 可視化	5
2.2.2 主成分分析	10
第 3 章 車線変更時刻推定法	13
3.1 逐次ベイズ推定	13
3.2 実計算での手続きやパラメータ設定	16
第 4 章 結果	17
4.1 推定結果のグラフ	17
第 5 章 考察	20
5.1 MAP, 重み付き平均について	20
5.2 推定の失敗について	20
第 6 章 結論	22
謝辞	23
参考文献	24

図目次

2.1	ある運転行動に対する，車線変更開始 10 秒前から車線変更開始までの特徴の組み合わせの散布図と，単一の特徴量のヒストグラム．上から（もしくは左から）順番に，アクセル，ブレーキ，ハンドル，前方車両との相対距離，前方車両との相対速度，前方車両との加速度考慮の TTC の逆数，右後方車両との相対距離，右後方車両との相対速度，右後方車両との加速度考慮の TTC の逆数となっている．プロットが緑から赤になるにつれて車線変更開始に近づいていることを示している．	6
2.2	車線変更開始 10 秒前から 0.5 秒前の時点における先行車両との相対距離と相対速度を，すべてのデータにおいてプロットした散布図．また，これを正規分布で近似し，長軸，短軸を標準偏差とした楕円．x 軸が距離を，y 軸が速度を表す．	10
2.3	図 2.2 における楕円をすべて重ねたもの．	11
2.4	主成分分析を行ったあとのデータ点から，各時刻ごとに二次元正規分布を求め，楕円としてプロットしたもの．楕円の大きさは，標準偏差の 1 倍になっている．緑から赤に近づくに連れて車線変更開始が近づいている．	12
3.1	正規分布を訓練データから流れる流れを図示したもの．各セルの中の値は特徴量 λ_1, λ_2 の一例を示している．各行はある車線変更の 1 試行において得られた特徴の推移を並べており，これらの 129 回分について平均，分散を求めることで，各時刻の属する正規分布を求めている．	14
3.2	各時刻に属する正規分布から，現在の観測の尤度を求め，ベイズの定理により観測が得られたあとの分布を計算する様子を図示したもの．オレンジは事前分布，緑が尤度で，赤が事後分布を表している．また，図示した特徴量での例として，重み付き平均，MAP による推定結果が幾つになるのかを示した．	15

- 4.1 32 回の推定結果の推移についての折れ線グラフと，平均，分散をエラーバーで示した図．左から順に，重み付き平均，MAP 推定，最尤推定の結果となっている．x 軸が実際の時間，y 軸が推定時間となっており，実際の時間と推定時間が一致する点を灰色の棒線で繋いでいる． 17
- 4.2 32 回の推定において得られた誤差をヒストグラムにし，3 つの結果をお互いに比較したもの．左から，MAP と最尤推定，最尤推定と重み付き平均，重み付き平均と MAP の比較結果となっている . 18

第 1 章 はじめに

1.1 背景

近年，自動車の普及台数は世界的に急速に増加 [1] しており，先進国，発展途上国問わず，自動車は人々の生活に欠かせないものとなっていくものと考えられる．一方で，自動車は未だ人々にとって十分に安全な乗り物とは言えない．世界では，交通事故により年間あたり 120 万人もの人が命を落としているという現状があり [1]，交通事故発生の対応策が必要であると考えられる．

交通事故の原因として，道路や交通の状況が考えられるが，人的要因もその一つである．速度違反，飲酒運転等の危険運転が交通事故に繋がるのは言うまでもないことであるが，脇見等の些細な不注意でも，危険運転同様に大きな事故に繋がる可能性がある．このような人的錯誤は，事前の注意喚起，教育による習慣形成，懲罰の設定等の制限による予防を危険運転ほどには望めないと考えられる．

そのため，不注意により発生する事故を事前に察知し，予防するような運転者を支援するシステムを導入するという方法が効果的であると考えられる．このようなシステムは，Advanced Driver Assistance System(ADAS) とよばれ，未来の乗り物として期待されている．前述したような運転者の支援には，運転者の行動予測が不可欠であり，このような予測システムを実現するには運転行動のモデル化が必要である．

運転行動のモデリングに関する研究は，大きく分けて巨視的な交通の流れを見るものと，微視的な個々の車両の行動に着目するものの 2 つに分かれている [2] が，本論文においては，「運転行動のモデル」は，後者の微視的なものを指すものとする．運転行動のモデリングを行った研究は数多く存在しているが，本論文では高速道路における車線変更をモデル化したものを扱うものとするが，本論文にて示す手法は他の運転行動に対しても応用可能である．高速道路において車線変更を予測するタスクを扱った論文として，Kumar[3] らの論文がある．この論文では，車線からの横方向の距離と，ハンドル角とその時間変化を特徴として，Support Vector Machine で分類した結果を Bayesian Filter で平滑化することで，白線を越える 1 秒前までに高い精度，再現率で車線変更開始を予測できた，としている．また，Morris[4] ら

は、多数のセンサを活用し RVM で車線変更タイミングを予測したところ、運転者の顔の角度から車線変更開始を予測できた、としている。

これらの既存の研究では、「車線変更を開始した時刻」の定義が、「車両が白線をまたいだときとなっており、運転者が車線変更開始に向けてハンドルを切った後にその検出に成功している。また、明確にいつ車線変更を開始するかの時刻を得られるわけではなく、その時点において車線変更を開始しそうかどうかを知ることしかできない。その為、実際に何秒後に車線変更するのか、ということや、運転者がハンドルを切ることになった根本的な原因は何にあるのかという、より進んだ車線変更開始モデルの構築が課題である。

運転行動、特に車線変更というタスクにおいては、自車両の動きだけでなく、周辺車両との関わり合いが大きな影響を及ぼすと考えられ、周辺車両情報を有効に活用することでより良い運転行動モデルを構築することが期待できるが、周辺車両とのかかわり合いを考慮した運転行動モデルについての研究は非常に少ない [5]。周辺車両との関わり合いの指標の一つとして、車両との衝突までの時間、Time to Collision(TTC) が挙げられる。森田 [6] らは、ブレーキを開始するまでのタイミングのの判別を行い、先行車両の大きさの変化率がブレーキのタイミングに寄与しており、TTC では判別困難であることを突き止めた、としている。

1.2 研究目的

本研究では、車線変更開始までの時刻を推定するための手法を開発することを第一の目標とした。また、有用であると考えられるにもかかわらず周辺車両との関係から特徴を抽出することはできていないため、周辺車両との自車両との関係性と車線変更開始までの時刻に如何な関係性があるのかを探ることも目標とした。

1.3 本論文の構成

本論文は以下のような構成を取る．まず，2章では，本研究の対象とした運転行動データの詳細と，車線変更開始前の運転行動データを可視化することにより，車線変更開始時刻の推定に有用な特徴や，本研究の手法を提案するに至るまでの考察を述べる．次に，3章では，車線変更開始タイミングの推定方法についての詳細や，実際の計算上で行った諸手続きについて述べる．4章，5章では，推定結果をもとに，得られた知見と，改善点を議論し，6章につなげる．

第 2 章 運転行動データと可視化

この章では、本研究において用いられた運転行動データの詳細について述べる。またこの運転行動データから、車線変更のタイミング推定に有用であると思われる特徴を抽出した後に、車線変更直前の特徴量の変化を可視化した。

2.1 運転行動データ

本研究においては、名古屋大学が収集した運転行動データを用いた。このデータには、10 名の被験者が名古屋高速道路を走行した際の、自車両の挙動や計器の情報、周辺車両との位置関係、走行中の道路の情報等の様々な運転行動が、サンプリングレート 10Hz で記録されている。これらの情報のうち、本研究で利用した情報を次に示す。

- 車線変更ラベル
- アクセルの踏み込み圧
- ブレーキの踏み込み圧
- ハンドルの操舵角
- 自車両中心と周辺車両中心点との相対位置
- 周辺車両との相対距離

車線変更ラベルは、運転者が車線変更の最中であるかどうかを表しており、左車線変更に-1、直進に 0、右車線変更に 1 の値が割り振られている。ここで、車線変更の開始のタイミングは、「車載カメラによる動画内で白線が左右に動き始めたとき」で、車線変更終了のタイミングは「その白線の動きが止まったとき」と定義されている。

周辺車両との相対位置、相対速度は車載のレーザーレンジファインダーを用いて計測されており、前後方に対して最大 100m の車両を検知することができる。相対位置、相対速度は、道路平面に対して車両進行方向と、その垂直方向の 2 次元に値を持っている。また、相対位置は、単に計測器から車の外縁までの距離を出しているのではなく、自車両、周辺車両の中心位置を推定して計測している。

高速道路における走行に際しては、普段通りに車線変更をして前方車両を抜かし、車両を抜かし終わったら走行車線へ戻るように被験者たちに指示がなされている。車線変更は、右車線変更左車線変更ともに、各被験者で平均 30 回程度行われており、すべてを合計すると、合計 341 回の右車線変更、335 回の左車線変更が行われていた。

2.2 特徴抽出

次に、この運転行動データを用いて、車線変更のタイミングの推定に有用だと思われる特徴の抽出を行った。まず、車線変更を行う前に何らかの特徴的な操作が現れる可能性を考え、車のアクセル、ブレーキの踏み込み圧、ハンドルの操作角を特徴量として定めた。

次に、周辺車両との関係性が車線変更に関わっていると考えられるため、これを特徴とする。対象とする周辺車両は、自車両に先行して走行している車両と自車両の右後方を走っている車両とする。特徴は、これらの周辺車両との相対距離、相対速度と、衝突までの時間 (TTC) とした。ただし、TTC は、加速度まで考慮したうえで逆数を計算した ($iTTC_{2nd}$)。ここで $iTTC_{2nd}$ は以下のように計算することができる。

$$iTTC_{2nd} = \frac{a_x^{rel}}{-2v_x^{rel} \pm \sqrt{(v_x^{rel})^2 - 2a_x^{rel}x}} \quad (2.2.1)$$

i

2.2.1 可視化

これらの特徴量が車線変更が始まる直前にどのような変化をするのかを見るために、車線変更開始 10 秒前から車線変更開始 0.5 秒前（これを「直前」と表す）までに取った値を、0.5 秒間隔でプロットした。まず、一回の車線変更に対して上記の特徴量それぞれの組み合わせをプロットしたものが、図 2.1 である。車線変更 10 秒前を緑色で、直前を赤色で、その間を黒として特徴量の変動を表している。対角の位置に当たるものがヒストグラムとなっている。ここから、どの特徴のヒストグ


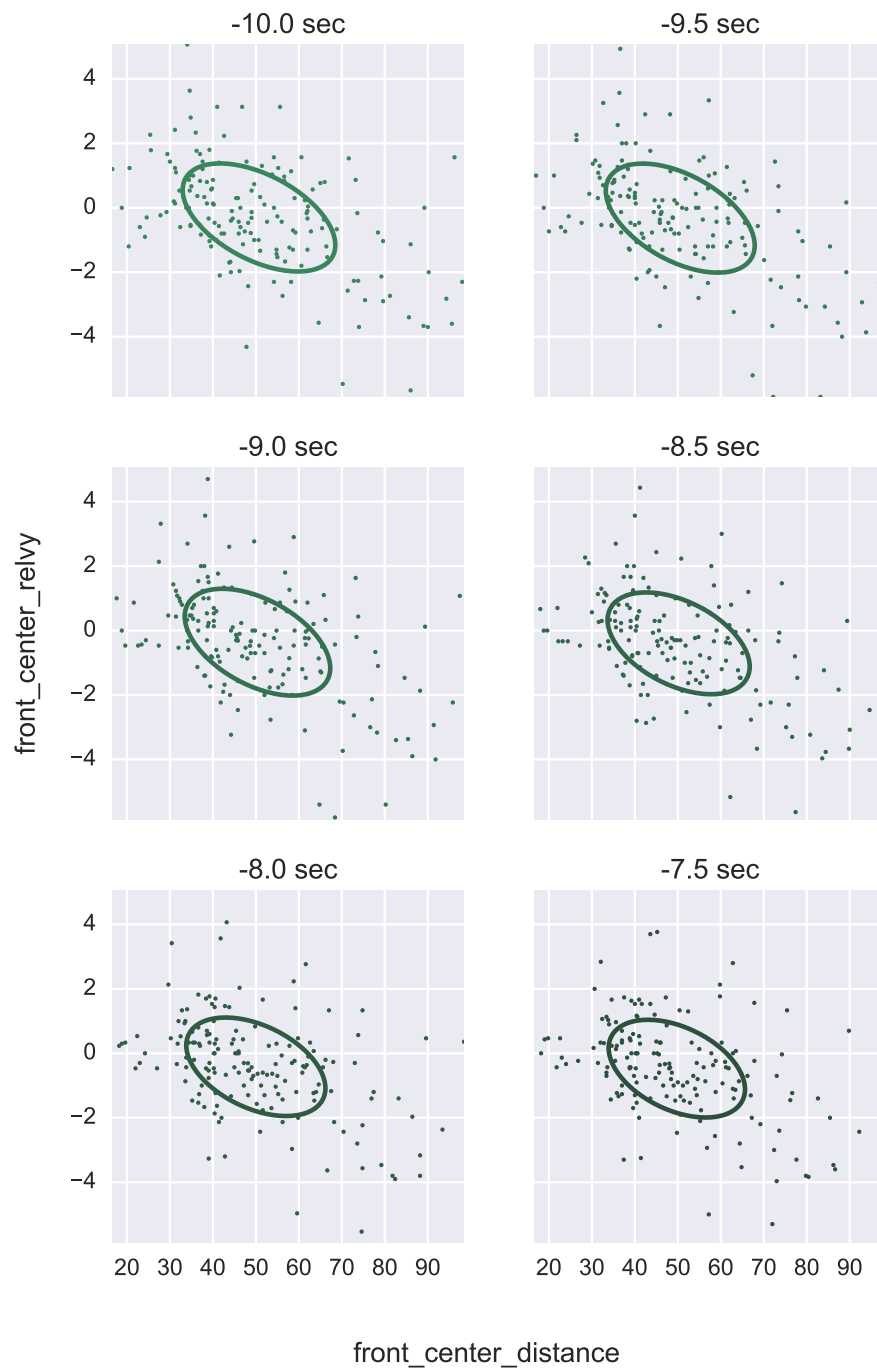
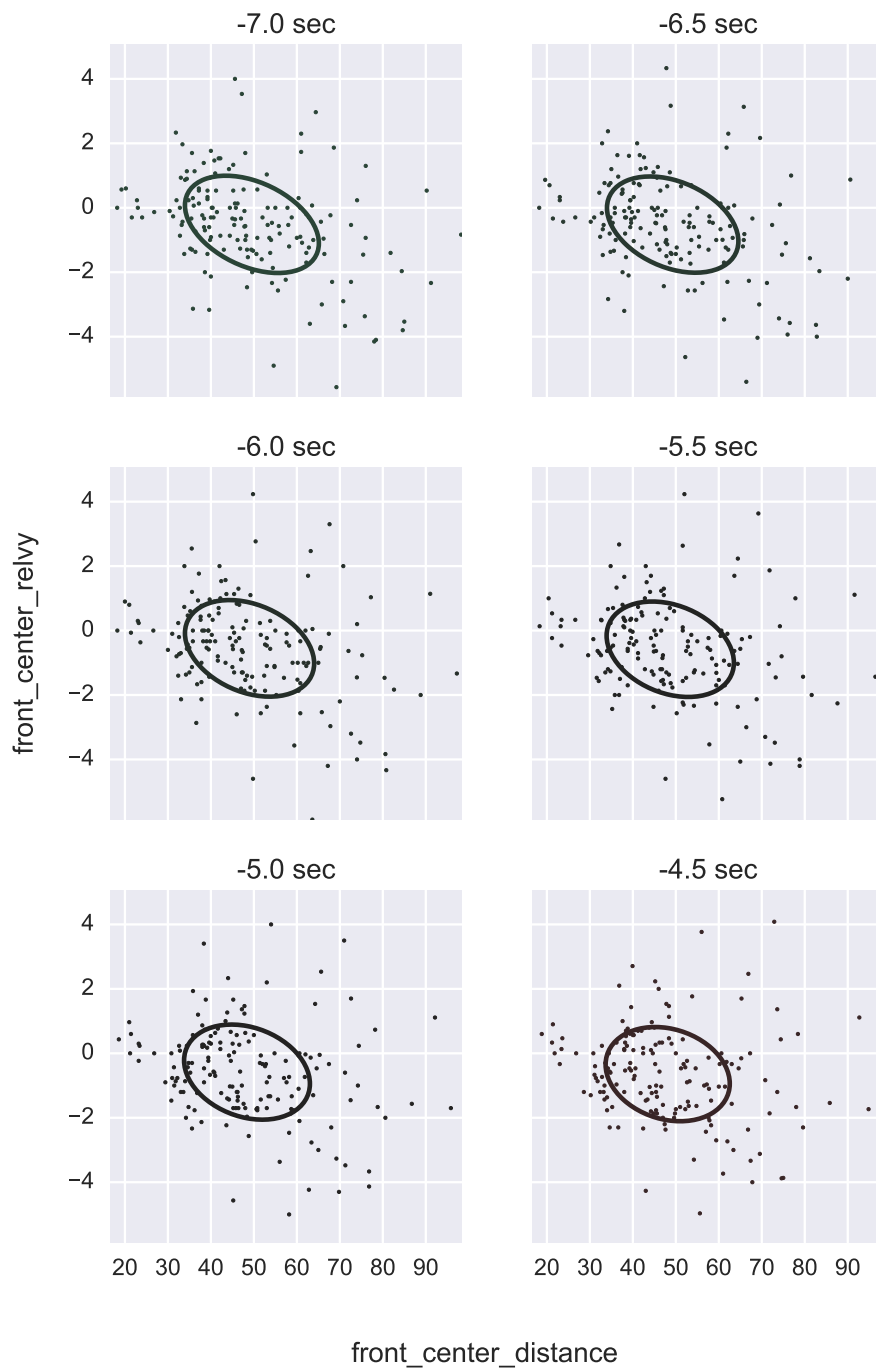


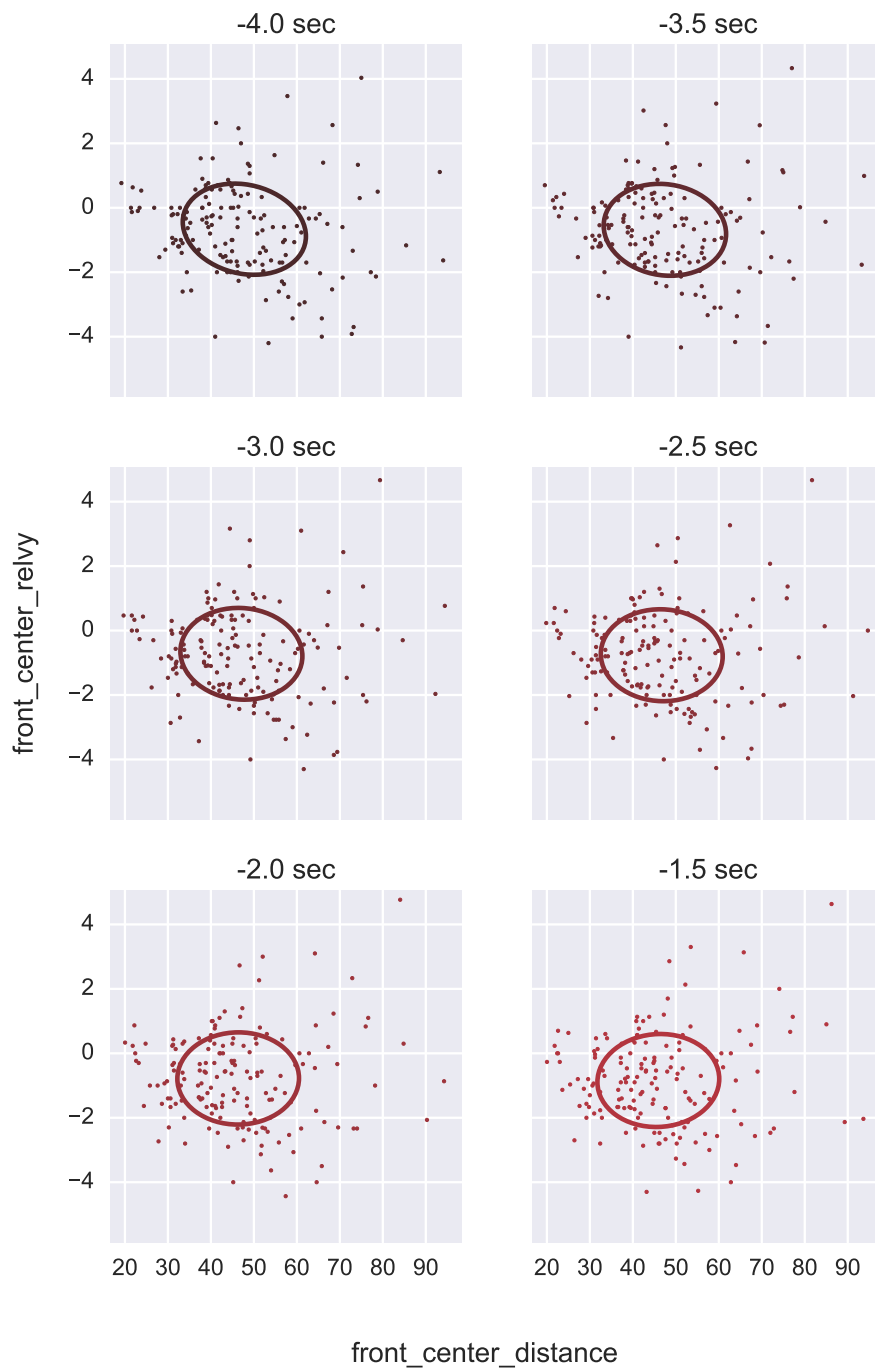
図 2.1 ある運転行動に対する，車線変更開始 10 秒前から車線変更開始までの特徴の組み合わせの散布図と，単一の特徴量のヒストグラム．上から（もしくは左から）順番に，アクセル，ブレーキ，ハンドル，前方車両との相対距離，前方車両との相対速度，前方車両との加速度考慮の TTC の逆数，右後方車両との相対距離，右後方車両との相対速度，右後方車両との加速度考慮の TTC の逆数となっている．プロットが緑から赤になるにつれて車線変更開始に近づいていることを示している．

ラムを見ても色が分離されておらず，単一の特徴から車線変更か否かの分離は困難であることがわかる．しかし散布図をみると，先行車両との相対距離，相対速度の組み合わせにおいて時系列に沿ってデータ点が並んでおり，特徴として有用であることが伺える．次に，先行車両との相対距離，相対速度の時系列に沿ったデータ点の移動の傾向を見るために，全時刻における，すべての車線変更トライアルについてのデータ点を表したものが図 2.2 である．また，すべての楕円をつなげたものが図 2.3 である．．これらから，車線変更開始前の各時刻における相対距離と相対速度は，二次元の正規分布に従っていると見ることができる．

また，0.5 秒ごとに散布図をつなげると，データ点が回転しながら収束していくように見ることができた．この情報を特徴として持たせるために特徴量の時間差分が必要だと考え，0.5 秒前のデータも特徴として盛り込み，以下に表されるような 4










図 2.2 車線変更開始 10 秒前から 0.5 秒前の時点における先行車両との相対距離と相対速度を、すべてのデータにおいてプロットした散布図。また、これを正規分布で近似し、長軸，短軸を標準偏差とした楕円。x 軸が距離を，y 軸が速度を表す。

次元の特徴とした。

$$feature_s(t) = \{distance_{s(t)}^{rel}, velocity_{s(t)}^{rel}, distance_{s(t+1)}^{rel}, velocity_{s(t+1)}^{rel}\} \quad (2.2.2)$$

ここで，n を 1 から 20 までの整数とすると時刻 $s(n)[sec]$ は $s(t) = t/2$ と表される。

2.2.2 主成分分析

この 4 次元の特徴を 2 次元に落とすために主成分分析 (PCA) を行った。このとき，上位 2 成分の寄与率は以下ようになった。二つの成分で，99% 超の成分を説

	第一主成分	第二主成分	第三主成分	第四主成分
寄与率	0.69	0.3	0.003	1.6e-05

表 2.1 pcaratio

明できることがわかる。また，PCA の主成分は，以下ようになる。また，PCA を行ったあとのデータ点から得られる正規分布の時間変化を楕円で表示したものを




図 2.3 図 2.2 における楕円をすべて重ねたもの.

0.66	0.27	0.00031	0.7
-0.25	0.66	-0.71	-0.019
0.67	0.22	-0.0088	-0.71
-0.24	0.67	0.71	-0.028

表 2.2 pcacomponents

図 2.4 に示す．これから，車線変更開始に近づくにつれて，楕円の平均がずれていき，分散が小さくなっており確率的には導出できそうだが，完全に分離することは難しいことがよみとれる．そのため，各時刻に対する正規分布を予め保持しておくことで逐次的に車線変更までのタイミングの確率分布を更新する手法が有効であると考えられる．この逐次的ベイズ推定のアプローチは，細胞分裂の時刻予測についての応用 [7] があり，車線変更予測にも有効性が期待できる．




図 2.4 主成分分析を行ったあとのデータ点から，各時刻ごとに二次元正規分布を求め，楕円としてプロットしたもの．楕円の大きさは，標準偏差の 1 倍になっている．緑から赤に近づくに連れて車線変更開始が近づいている．

第 3 章 車線変更時刻推定法

前章では、車線変更前の前方車両との距離、速度を用いて得られた成分が、二次元の正規分布に従っていると考えられることを示した。本章においては、この仮定を用いて、逐次的に車線変更を行う時刻を推定する手法について解説する。まず、逐次ベイズ推定による時系列データの一般的な扱いや、正規分布の定義から尤度関数を導出する方法について述べる。次に、事前分布の仮定や、尤度関数による事後分布の更新方法を述べる。最後に、実際に運転行動データに適用する際に設定したパラメータや諸手続きの詳細について述べる。

3.1 逐次ベイズ推定

車線変更開始時点をもととしたときの現在の時刻を τ (T 以上の負の整数) と置く。はじめに、 τ に属する正規分布を $T \times N$ 次元のデータ行列 \mathbf{D}_{train} から求める。 \mathbf{D}_{train} の要素 $\mathbf{x}_{\tau,n}$ は、観測により得られた各特徴のベクトルとなっている。また、ある観測の系列を \mathcal{D}_n とおく。以下、 $T = -20$, $N = 2$ と考え、 $\mathbf{x} = (\lambda_1, \lambda_2)$ とする。

\mathbf{D}_{train} から、各時刻 τ に属する正規分布 \mathcal{N}_τ を求める。まず、二次元の正規分布は

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{2\pi |\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right\} \quad (3.1.1)$$

と書ける。ただし、 $\boldsymbol{\mu}$ は 2 次元の平均ベクトル、 $\boldsymbol{\Sigma}$ は 2×2 の共分散行列、 $|\boldsymbol{\Sigma}|$ は $\boldsymbol{\Sigma}$ の行列式である。 \mathcal{N}_τ の平均 $\boldsymbol{\mu}_\tau$ 、共分散行列 $\boldsymbol{\Sigma}_\tau$ を最尤推定で求めると、

$$\boldsymbol{\mu}_\tau = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n \quad (3.1.2)$$

$$\boldsymbol{\Sigma}_\tau = \frac{1}{N-1} \sum_{n=1}^N (\mathbf{x}_{\tau,n} - \boldsymbol{\mu}_\tau)(\mathbf{x}_{\tau,n} - \boldsymbol{\mu}_\tau)^T \quad (3.1.3)$$

となる。それぞれ、サンプルの平均、不偏分散に等しい。訓練データから平均、分散を求める仮定を図示したものが、図 3.1 である。トレーニングデータ 129 個を各

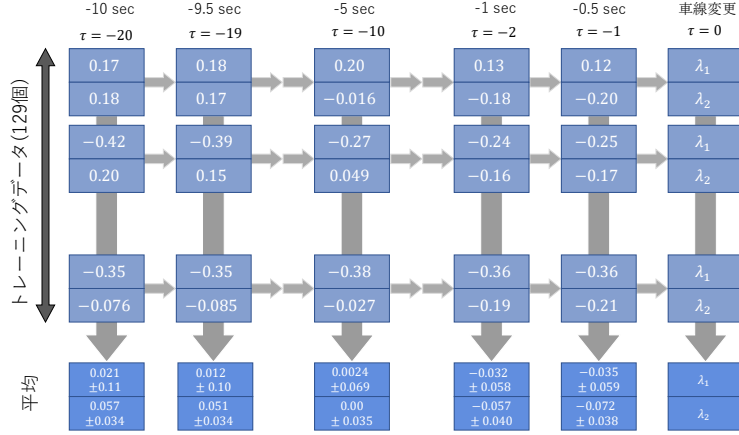


図 3.1 正規分布を訓練データからの流れを図示したもの。各セルの中の値は特徴量 λ_1, λ_2 の一例を示している。各行はある車線変更の 1 試行において得られた特徴の推移を並べており、これらの 129 回分について平均，分散を求めることで，各時刻の属する正規分布を求めている。

時刻ごとにまとめ，平均，分散を出力することで，各時刻が属する正規分布を得ている。

次に， τ に対し事前分布をおき，正規分布から与えられる尤度によって車線変更開始までの時間を逐次的に更新することを考える。自車両と周辺車両の関係についての観測値が与えられていない時， τ は一様分布であると仮定する。この時事前分布は

$$p(\tau) = 1/T \quad (3.1.4)$$

と表される。

観測値が得られた時，時刻 τ に対する確率分布 $p(\tau)$ を更新する。観測値 \mathbf{x}_1 が得られたときの尤度は

$$p(\tau|\mathbf{x}_1) = \mathcal{N}(\mathbf{x}_1|\boldsymbol{\mu}_\tau, \boldsymbol{\Sigma}_\tau) \quad (3.1.5)$$

となる．よって一度目の更新で得られる事後分布 $p(\tau|\mathbf{x}_1)$ は以下のように表される．

$$p(t|\mathbf{x}_1) \propto p(\mathbf{x}_1|\tau)p(\tau-1) = \frac{1}{N} \frac{1}{2\pi |\Sigma|_\tau^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x}_1 - \boldsymbol{\mu}_\tau)^T \Sigma_\tau^{-1} (\mathbf{x}_1 - \boldsymbol{\mu}_\tau) \right\} \quad (3.1.6)$$

ここで，時刻 τ となる確率が $p(\tau-1)$ に依存しているが，これは，新しい観測値を得るまでに経過した時間により，車線変更開始までの時刻 τ に発生するズレを補正することに起因する．更新により得られる事後分布は $\int p(\tau) d\tau = 1$ を満たしていないため， $\sum_\tau p(\tau|\mathbf{x}_1)$ ですべての値を割ることで正規化を施す必要がある．この更新の過程を図示したものが，図 3.2 である．ある観測点を得られたとき，その観

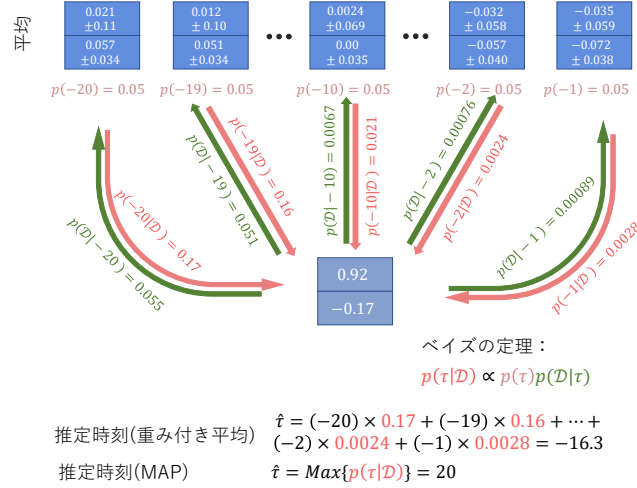


図 3.2 各時刻に属する正規分布から，現在の観測の尤度を求め，ベイズの定理により観測が得られたあとの分布を計算する様子を図示したもの．オレンジは事前分布，緑が尤度で，赤が事後分布を表している．また，図示した特徴量での例として，重み付き平均，MAP による推定結果が幾つになるのかを示した．

測点が各時刻にどれだけ尤もらしいかを計算し，各時刻である確率分布を更新している．

この更新の結果を一般化し， k 回観測値を得られたときのデータ集合 $\mathcal{D}_k = \{\mathbf{x}_1, \dots, \mathbf{x}_k\}$ から事後分布を求める．一度の観測で一単位時間が動くことを考える

と、事後分布 $p(\tau|\mathbf{x}_1)$ は以下のように表される.

$$p(\tau|\mathcal{D}_k) \propto \frac{1}{N} \prod_{i=1}^k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_{\tau-i+k}, \boldsymbol{\Sigma}_{\tau-i+k}) \quad (3.1.7)$$

例えば, 3 回分の観測データが与えられたとき, $\tau = -5$ となる確率を求めるには, 一つ目の観測が得られたときに $\tau = -7$ となる尤度を, 二つ目の観測が得られたときに $\tau = -6$ となる尤度を, そして 3 回目のデータが得られたときに $\tau = -5$ となる尤度を計算して掛け合わせればよい.

以上が車線変更時刻の推定のために用いた逐次ベイズ推定の方法である.

3.2 実計算での手続きやパラメータ設定

計算上では, 尤度を掛け合わせていくと非常に小さな値となってしまう誤差が発生してしまうため, 実際は対数尤度の和を用いて計算を行った. また今回, T を 20 と, 観測値の取得間隔を 0.5 秒毎と設定した. よって, $\tau = 20$ は車線変更開始の 10 秒前を表す. \mathbf{x}_τ については, 時刻 τ のときの周辺車両との相対位置, 相対速度と, $\tau + 1$ のときの周辺車両との相対位置, 相対速度の 4 次元ベクトルに対し, 主成分分析によって 2 次元に落とし込んだものを観測値とした.

また, すべての右車線変更 161 回のうち, 4/5 にあたる 129 回を訓練データに, 1/5 に当たる 32 回をテストデータとした. 訓練データを主成分分析にかけ, 各 τ の属する正規分布を導出した後, テストデータにも訓練データにより得られた変換を施し, 変換を施したテストデータを用いて上述のベイズ推定を行い, 各時刻の推定結果を重み付き平均, MAP 推定の 2 つの方法で導出した.

第 4 章 結果

本章では，3 章で述べた推定の結果を，最尤推定の結果と比較して議論する．

4.1 推定結果のグラフ

ランダムに分割したテストデータ 32 個に対し，各時刻に推定を行った結果を，時系列ごとに出力した図が図 4.1 である．左に示した，水色のグラフは，重み付き平

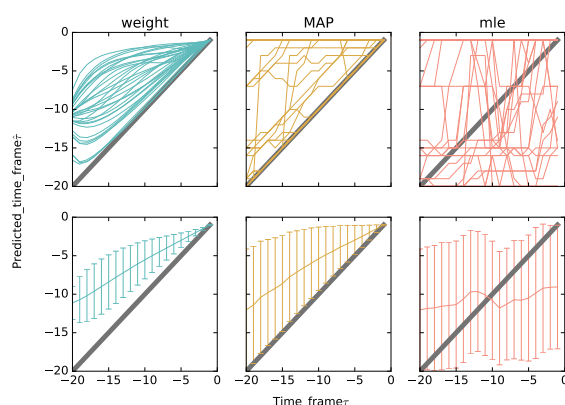


図 4.1 32 回の推定結果の推移についての折れ線グラフと，平均，分散をエラーバーで示した図．左から順に，重み付き平均，MAP 推定，最尤推定の結果となっている．x 軸が実際の時間，y 軸が推定時間となっており，実際の時間と推定時間が一致する点を灰色の棒線で繋いでいる．

均による推定結果，中央の黄色のグラフは，MAP 推定による結果，右のオレンジのグラフは，最尤推定により求めた結果を表している．上の 3 つの図が，各系列での推定結果の推移を表したもので，下の 3 つの図が，各試行での平均推定時間の推移と，各時刻における散らばりを分散によって示している．中央の灰色の直線は，推定結果の誤差が 0 となる線を示している．まず，重み付き平均のときは，他と比べ急激に推定結果は変わらず，徐々に推定結果を変化させて行っていることがわかる．対して，MAP 推定では，推定の推移の仕方は概ね以下の傾向に分かれていることがわかる．

- 最初から最後まで正確に推定を続けているもの（灰色の線に乗っているもの）
- 直前であると推定し続けているもの（ $\hat{\tau} = -1$ に張り付いた水平の線）
- 途中から推定結果が改善されるもの

また、2つの手法で共通して、エラーバーは徐々に小さくなっており、推定が進むにつれて結果が改善されていっていることが読み取れる。最後に、最尤推定の結果では、全時間帯において推定結果が激しく変動しており、また、平均の推定結果についても非常にばらつきが大きくなってしまっていることがわかる。

重み付き平均において、推定を開始した段階では $\hat{\tau} = -10$ 付近であるとする推定結果が多く見られるが、これは、推定結果を平均として出す関係上、結果が分布の中心点に引っ張られてしまいやすいという特性が存在しているためである。これは、MAP 推定において平均を取ったときにも同様に現れる傾向である。

次に、推定結果の誤差をヒストグラムとして表し、各手法を比較したものが図 4.2 である。先程のものと同じく、水色が重み付き平均、黄色が MAP、オレンジが最




図 4.2 32 回の推定において得られた誤差をヒストグラムにし、3つの結果を互いに比較したもの。左から、MAP と最尤推定、最尤推定と重み付き平均、重み付き平均と MAP の比較結果となっている

尤推定である。x 軸が誤差、y 軸は誤差が出現する頻度を表している。重み付き平均、MAP の両手法とも、最尤推定よりも中心付近、つまり推定誤差が小さいときの頻度が大きくなっている。特に、MAP は、中心の推定誤差 0 が際立って大きくなっている。正確な結果を出力する頻度が高いことは、重み付き平均に比べて MAP の利点であると考えられる。しかし逆に、重み付き平均ではほとんど現れない 19 や 20 もの誤差が出現する場合がある。これは、最初から最後まで車線変更直

前である，と完全に推定を失敗してしまう可能性が MAP には存在するからである．ある程度の誤差を許容し安定した結果を出したいなら重み付き平均を，完全に失敗する 때가 あっても，正確に推定することが多いほうが好ましいなら MAP を採用すべきだろう．

第 5 章 考察

5.1 MAP, 重み付き平均について

本研究の提案手法の評価として, MAP, 重み付き平均の両方における推定結果を比較した. 重み付き平均では中心部に引っ張られてしまい, 大きな誤差は出ないが, 完全に推定結果が一致することは少なかった. MAP では, 完全に推定結果が一致することもあるれば, 全く結果が一致しないこともあった. 4 章でも述べたように, これらの結果は一長一短である. 単純に MAP, 重み付き平均ではなく, これらの両方を考慮した評価基準を考案することにより, 推定結果の改善が図れるとかがえられる.

5.2 推定の失敗について

提案手法により得られた分布を MAP を用いて推定を行うと, 常に「車線変更開始直前である」という推定結果が一定数存在していることがわかった. つまり, 運転者の行動によっては, 車線変更のタイミング推定が失敗することが考えられる. 原因としては, 図 2.4 に見る通り, 各時刻に属する特徴量の正規分布が未だ十分な分離ができていないということがあげられる. また, 全時刻で直前と推定されてしまうことから, 車線変更開始 10 秒前から直前まで一貫して同じ相対距離, 同じ相対速度をドライバーが維持し続けている, というのも原因として考えられる. これらを根本的に解決する方法としては, より車線変更開始時刻を決定づける特徴量を発見することが必要である.

実際の運転行動から, 前方車両の距離と速度には法則性がみられた. 一つは, 等速を維持したまま距離を詰め, そのまま車線変更を開始する, という場合である. これは単純に, 前方車両が障害となるため回避行動を行ったとかがえられる. もう一つは, 30m 程度の距離を維持して, 減速の後加速しながら車線変更を開始する場合である. ドライバーは一旦車線変更をやめて前方車両の後ろに付き, その後車線変更を開始していた. 状況として, 追い越し車線に車両がいたため, 車線変更を一旦やめている事が考えられる. このような状況では, 前方車両だけでなく, 追い

越し車線の車両についても推定に有用であると考えられる。本研究における将来的な課題は、この追い越し車線の車両について有用な特徴量の表現を探ることである。

第 6 章 結論

本研究では，運転行動のモデリングの課題の一つとして，運転者による車線変更の時刻推定を目標とした．まず，車線変更開始時刻を決定づける要因として，どのような特徴量が関わっているのかを調査した．その結果，自車両の前方車両との相対距離と相対速度が特徴量として有用そうであるということを突き止めた．次に，相対距離，相対速度が車線変更開始前にどのように分布しているのかを調べたところ，データ点は，二次元の正規分布で近似できそうであること，データ点が回転しながら収束しているように見えることがわかった．ここから，回転の情報を保持するために，変位の情報を加えた 4 次元のベクトルに主成分分析をかけることによって 2 次元に落とし込んだものを特徴量とした．

この特徴量から車線変更の開始時刻を推定するために，車線変更開始時間の持つ分布を逐次的に更新するベイズ的な手法をもちいた．この手法により得られた分布から，MAP，重み付き平均の両方で時刻を推定したところ，データ点の取得が進むほどに推定時刻が改善されていくことが確認できた．

謝辞

本研究の遂行，及び論文の作成にあたっては，多くの方々のご指導，ご協力をいただきました．本研究に関して終始ご指導ご鞭撻をいただきました指導教員の池田和司教授に深く感謝申し上げます．また，安本慶一教授には，研究発表にて大変有用なご助言をしていただき，感謝の念に耐えません．また，熱心なご指導と，数々の有益な助言を賜りました，久保孝富特任准教授に深く御礼を申し上げます．そして，研究室での生活を影から支えてくださった秘書の谷本史さんに心から感謝申し上げます．最後に，何かと日常でお世話になった研究室の皆さんに感謝の意を表し，謝辞を締めくくらせていただきます．

参考文献

- [1] World Health Organization. *Global Status Report on Road Safety 2015*. World Health Organization, 2016.
- [2] Sven Maerivoet and Bart De Moor. Traffic flow theory. Technical report, Department of Electrical Engineering in Katholieke Universiteit Leuven, July 2005.
- [3] P. Kumar, Mathias Perrollaz, Stéphanie Lefèvre, and Christian Laugier. Learning-based approach for online lane change intention prediction. In *IEEE Intelligent Vehicles Symposium*, Gold Coast, Australia, June 2013.
- [4] Brendan Morris, Anup Doshi, and Mohan Trivedi. Lane change intent prediction for driver assistance: On-road design and evaluation. In *2011 IEEE Intelligent Vehicles Symposium (IV)*. Institute of Electrical and Electronics Engineers (IEEE), jun 2011.
- [5] Stéphanie Lefèvre, Dizan Vasquez, and Christian Laugier. A survey on motion prediction and risk assessment for intelligent vehicles. *ROBOMECH Journal*, Vol. 1, No. 1, p. 1, 2014.
- [6] 森田和元, 大野督史, 関根道昭. Time-to-collision はブレーキ操作タイミングを決定するか. 第4回 ITS シンポジウム 2005. ITS Japan, 2005.
- [7] Satoshi Kozawa, Takashi Akanuma, Tetsuo Sato, Yasuomi D. Sato, Kazushi Ikeda, and Thomas N. Sato. Real-time prediction of cell division timing in developing zebrafish embryo. *Scientific Reports*, Vol. 6, p. 32962, sep 2016.